

Sistemi e Architetture per Big Data - A.A. 2025/26

Progetto 1: Analisi di dati sui voli con Apache Spark

Docenti: Valeria Cardellini, Matteo Nardelli
Dipartimento di Ingegneria Civile e Ingegneria Informatica
Università degli Studi di Roma "Tor Vergata"

Requisiti del progetto

Lo scopo del progetto è usare il framework di data processing Apache Spark per rispondere ad alcune query su dati storici relativi ai voli aerei, forniti dal Dipartimento dei trasporti degli Stati Uniti d'America¹.

Per gli scopi di questo progetto, viene fornita una versione preprocessata del dataset, disponibile al seguente URL²: <http://www.ce.uniroma2.it/courses/sabd2526/project/project-1-data.tar.gz>.

Il dataset considerato contiene informazioni sui voli operati negli Stati Uniti, incluse informazioni temporali, sull'aeroporto di partenza e di arrivo, sul ritardo e sullo stato del volo. Il dataset contiene circa 2.200.000 eventi, che descrivono i voli effettuati nel periodo dal 1 gennaio 2025 al 30 aprile 2025. Ogni evento del dataset descrive un singolo volo ed è caratterizzato da informazioni quali:

- **Compagnia aerea** (OP_UNIQUE_CARRIER);
- **Data del volo**, comprensiva di anno, mese e giorno (YEAR, MONTH, DAY_OF_MONTH);
- **Aeroporto di partenza e di arrivo** (ORIGIN_AIRPORT_ID, DEST_AIRPORT_ID);
- **Orario schedato di partenza** (CRS_DEP_TIME);
- **Ritardo in partenza e in arrivo** (DEP_DELAY, ARR_DELAY), espressi in minuti; possono assumere anche valori negativi (voli in anticipo);
- **Stato del volo**, inclusa l'informazione se il volo è stato cancellato (CANCELLED) o deviato (DIVERTED);
- **Cause del ritardo**, tra cui ritardi dovuti alla compagnia, alle condizioni meteo, al sistema aeroportuale, alla sicurezza e al ritardo dell'aeromobile precedente (CARRIER_DELAY, WEATHER_DELAY, NAS_DELAY, SECURITY_DELAY, LATE_AIRCRAFT_DELAY).

Per gli scopi del progetto, sono di interesse in particolare:

- il *ritardo in partenza* (DEP_DELAY);
- il *ritardo in arrivo* (ARR_DELAY);
- il *tasso di cancellazione*, definito come la percentuale di voli cancellati sul totale dei voli considerati;
- le *cause del ritardo*, per analizzare i fattori che contribuiscono ai ritardi dei voli.

¹<https://www.transtats.bts.gov/>

²sha1sum del file compresso in TAR GZ: 17be276b72bd987e72598b0ea4907c3b19350606

Dataset

Durante la fase di data ingestion, valutare il modo più opportuno di memorizzare i dati, ad esempio tramite file separati (per giorno, mese o altra granularità temporale) oppure tramite un unico file per l'intero periodo da gennaio ad aprile. Inoltre, per gli scopi del progetto, sono di interesse solo i dati necessari a identificare la compagnia aerea, la data del volo, l'orario schedato di partenza, il ritardo, lo stato del volo e le principali cause del ritardo.

Si noti che alcuni campi, in particolare quelli relativi alle cause del ritardo, possono contenere valori mancanti.

Query

Considerando il dataset indicato, le query a cui rispondere sono:

Q1 Facendo riferimento al dataset dei voli relativi alle compagnie aeree AA (American Airlines) e DL (Delta), aggregare i dati su base mensile. Calcolare la media, il minimo ed il massimo di DEP_DELAY e il CANCELLATION_RATE per ciascun mese (in esame) del 2025. Il CANCELLATION_RATE deve essere calcolato come la percentuale di voli cancellati sul totale dei voli osservati per ciascuna compagnia e per ciascun mese. Nel calcolo delle statistiche relative ai ritardi (DEP_DELAY, ARR_DELAY), considerare *esclusivamente* i voli non cancellati. Il CancellationRate deve invece essere calcolato considerando tutti i voli osservati nel gruppo di aggregazione. Inoltre, considerando il valor medio di DEP_DELAY e il CANCELLATION_RATE aggregati su base mensile, generare due grafici che consentano di confrontare visivamente l'andamento per AA e DL.

ESEMPIO DI OUTPUT

```
# month, airline, dep-delay-mean, dep-delay-min, dep-delay-max, cancellation-rate
1, C1, 12.54, -18.00, 214.00, 1.83
2, C1, 15.02, -20.00, 231.00, 2.11
...
1, C2, 10.11, -17.00, 201.00, 1.42
2, C2, 11.98, -19.00, 223.00, 1.67
...
```

(i valori indicati non sono significativi rispetto all'output atteso)

Q2 Per ciascuna compagnia (OP_UNIQUE_CARRIER), calcolare il numero totale di voli non cancellati (CANCELLED) e non deviati (DIVERTED), il valor medio di ARR_DELAY e il valor medio delle componenti di ritardo CARRIER_DELAY, WEATHER_DELAY, NAS_DELAY, SECURITY_DELAY e LATE_AIRCRAFT_DELAY. Si considerino solo le compagnie con almeno 500 voli non cancellati e non deviati nel periodo osservato. Calcolare quindi la classifica delle prime 10 compagnie ordinate per ARR_DELAY medio decrescente. Per ciascuna delle 10 compagnie in classifica, mostrare il contributo medio delle diverse cause di ritardo. Si noti che le componenti di ritardo possono contenere valori mancanti; tali valori possono essere trattati come zero oppure ignorati, purché la scelta sia chiaramente motivata.

Infine, generare un grafico che mostri la classifica delle 10 compagnie in base al ritardo medio in arrivo e un grafico che consenta di confrontare, per tali compagnie, l'incidenza media delle diverse cause di ritardo.

ESEMPIO DI OUTPUT

```
# carrier, num_flights, arrdelay_mean, \
  carrier_delay_mean, weather_delay_mean, nas_delay_mean, \
  security_delay_mean, late_aircraft_delay_mean
F9, 12543, 18.42, 4.91, 0.62, 3.14, 0.03, 5.27
B6, 18821, 17.95, 3.88, 0.71, 3.92, 0.02, 4.86
...
```

(i valori indicati non sono significativi rispetto all'output atteso)

Q3 Facendo riferimento al dataset dei voli relativi alle compagnie aeree AA (American Airlines), DL (Delta), UA (United), e WN (Southwest), aggregare i dati di ciascuna compagnia sulle 24 ore della giornata. L'ora del giorno deve essere ricavata a partire dal campo `CRS_DEP_TIME`, considerando le 24 fasce orarie giornaliere. Per ciascuna compagnia e per ciascuna fascia oraria, considerare i valori di `DEP_DELAY` dei voli non cancellati e calcolare il 25-esimo, 50-esimo (mediana), 75-esimo e 90-esimo percentile. Inoltre, per ciascuna compagnia, calcolare il minimo e il massimo di `DEP_DELAY` sull'intero dataset.

Si richiede di utilizzare tecniche efficienti per il calcolo dei percentili su grandi volumi di dati, ad esempio utilizzando le funzioni di approssimazione fornite da Spark oppure implementare metodi alternativi (e.g., t-digest [1], KLL sketch [3]).

Infine, generare grafici che consentano di confrontare, per ciascuna compagnia, la distribuzione dei ritardi nelle diverse fasce orarie.

ESEMPIO DI OUTPUT

```
# airline, hour, p25, p50, p75, p90
AA, 0, 2.1, 5.3, 9.8, 18.4
AA, 1, 1.8, 4.9, 8.7, 15.2
...
DL, 0, 1.9, 4.7, 8.1, 14.9
...

# airline, min_delay, max_delay
AA, -25.0, 310.0
DL, -22.0, 285.0
...
```

(i valori indicati non sono significativi rispetto all'output atteso)

Il risultato di ciascuna query deve essere consegnato in formato CSV.

Per la rappresentazione grafica dei risultati delle query, utilizzare un framework di visualizzazione (e.g., Grafana [2]).

Inoltre, si chiede di valutare sperimentalmente i tempi di processamento delle query sulla piattaforma di riferimento usata per la realizzazione del progetto e di riportare tali tempi nella relazione e nella presentazione del progetto. Tale piattaforma può essere un nodo standalone (si suggerisce di utilizzare Docker Compose), oppure è possibile utilizzare un servizio cloud per il processamento di Big Data (e.g., Amazon EMR) avvalendosi del grant a disposizione.

Infine, si chiede di realizzare la fase di data ingestion per:

- importare i dati di input in HDFS, eventualmente gestendo la conversione del formato dei dati, usando un framework di data ingestion a scelta (e.g., Apache NiFi, Apache Kafka, Apache Pulsar);
- esportare i risultati di output da HDFS ad un sistema di storage a scelta (e.g., HBase, Redis).

Composizione dei gruppi

Il progetto è dimensionato per un gruppo composto da **2 studenti**.

Per gruppi composti da 1 studente: si richiede di rispondere alle query 1 e 2; inoltre, la gestione del data ingestion è opzionale, ma il dataset deve comunque essere scaricato dal sito, letto da HDFS ed i risultati di output scritti su HDFS.

Per gruppi composti da 3 studenti: in aggiunta ai requisiti sopra elencati, eseguire un'analisi di clustering sulle compagnie presenti nel dataset. Per ciascuna compagnia aerea, calcolare un insieme di feature rappresentative del comportamento operativo, tra cui:

- il valor medio di `DEP_DELAY`;
- il valor medio di `ARR_DELAY`;
- il `CancellationRate`;
- il contributo medio delle diverse cause di ritardo (`CARRIER_DELAY`, `WEATHER_DELAY`, `NAS_DELAY`, `SECURITY_DELAY`, `LATE_AIRCRAFT_DELAY`).

A tal fine, è possibile utilizzare strumenti di feature engineering (e.g., `VectorAssembler`) per costruire il vettore delle feature e tecniche di normalizzazione o standardizzazione per rendere le feature confrontabili. Si suggerisce di normalizzare le feature prima dell'applicazione dell'algoritmo di clustering. L'obiettivo è individuare gruppi di compagnie con comportamenti simili in termini di ritardi e cause dei ritardi, utilizzando l'algoritmo di clustering *k-means*.

Oltre ad applicare l'algoritmo di clustering sui dati, determinare un valore ottimale di *k* (numero di cluster) mediante l'uso di metriche appropriate, come ad esempio *elbow method*³ o l'*indice di silhouette*⁴. Si considerino le compagnie aeree con il maggior numero di voli nel dataset (ad esempio le prime 10–15 compagnie per numero di voli), in modo da garantire la significatività dei risultati. Infine, interpretare i cluster ottenuti, evidenziando le principali differenze tra i gruppi individuati.

Generare un grafico che consenta di visualizzare il risultato del clustering.

Opzionale: Si richiede di utilizzare Spark SQL per rispondere alle tre query utilizzando SQL. Si chiede inoltre di valutare sperimentalmente i tempi di processamento delle 3 query ottenuti con Spark SQL e di confrontarli con quelli ottenuti usando il solo framework Spark, riportando l'analisi del confronto nella relazione e nella presentazione.

Svolgimento e consegna del progetto

Per ogni comunicazione via email è necessario specificare *[SABD]* nell'oggetto (subject) dell'email.

Comunicare la composizione del gruppo ai docenti entro **venerdì 15 maggio 2026**. Il progetto è valido solo per l'A.A. 2025/26 ed il codice e la relazione devono essere consegnati **entro venerdì 5 giugno 2026**.

La consegna del progetto consiste in:

³[https://en.wikipedia.org/wiki/Elbow_method_\(clustering\)](https://en.wikipedia.org/wiki/Elbow_method_(clustering))

⁴[https://en.wikipedia.org/wiki/Silhouette_\(clustering\)](https://en.wikipedia.org/wiki/Silhouette_(clustering))

1. link a spazio di Cloud storage o repository contenente il codice del progetto e la relazione, da comunicare via email ai docenti **entro venerdì 5 giugno 2026**; inserire i risultati delle query in formato CSV in una cartella denominata `Results`.
2. relazione di lunghezza compresa tra le 4 e le 8 pagine, da inserire all'interno della cartella denominata `Report`; per la relazione si consiglia di usare il formato ACM proceedings (<https://www.acm.org>) oppure il formato IEEE proceedings (<https://www.ieee.org>); includere nella relazione lo schema dell'architettura di sistema utilizzata e l'analisi dei risultati sperimentali.
3. slide della presentazione orale, da inviare via email ai docenti **dopo** lo svolgimento della presentazione.

La presentazione si terrà **lunedì 12 giugno 2026** (da confermare); ciascun gruppo avrà a disposizione **massimo 15 minuti** per presentare la propria soluzione (20 minuti per gruppi composti da 3 persone).

Valutazione del progetto

I principali criteri di valutazione del progetto saranno:

1. rispondenza ai requisiti;
2. originalità;
3. architettura del sistema e deployment;
4. organizzazione del codice;
5. efficienza;
6. organizzazione, chiarezza e rispetto dei tempi della presentazione orale.

Riferimenti bibliografici

- [1] T. Dunning. The t-digest: Efficient estimates of distributions. *Software Impacts*, 7:100049, 2021. [https://www.softwareimpacts.com/article/S2665-9638\(20\)30040-3/fulltext](https://www.softwareimpacts.com/article/S2665-9638(20)30040-3/fulltext).
- [2] Grafana. <https://grafana.com/grafana/>.
- [3] Z. Karnin, K. Lang, and E. Liberty. Optimal quantile approximation in streams. In *Proc. of IEEE 57th Annual Symposium on Foundations of Computer Science (FOCS '16)*, pages 71–78, 2016.