



TOR VERGATA
UNIVERSITÀ DEGLI STUDI DI ROMA

Sky Analytics Engine

Analisi batch e Metriche del Traffico Aereo

Flavio Simonelli Francesco Masci

Corso Architettura e Sistemi per Big Data
Corso di Laurea Magistrale in Ingegneria Informatica
Università di Roma "Tor Vergata"

12 Giugno 2026

Architettura e Flusso

Extraction e Ingestion Layer


Computation Layer

Orchestration Layer


Valutazione Sperimentale

Risultati Analitici

Big Data Stack & Flow Diagram



Componenti del Big Data Stack




Flusso di interazione dei componenti

NiFi Ingestion Pipeline: REST Trigger

- **Design Data-Driven:** Pipeline stateless configurata dinamicamente in base al payload JSON iniettato all'avvio da Airflow.
- **Avvio della Pipeline:**
 - **HandleHttpRequest:** espone l'endpoint REST per intercettare l'avvio.
 - **ValidateJson:** esegue il controllo strutturale rigoroso tramite JSON Schema.
- **Propagazione della Configurazione:**
 - **EvaluateJsonPath:** estrae e mappa le chiavi JSON in Attributi del FlowFile.
 - I metadati guidano le decisioni successive del processing.

Payload JSON

```
{
  "job_id": "FLIGHT_INGEST_run_123",
  "ingestion": {
    "source_type": "HTTP",
    "http_url": "http://www.ce.uniroma2.it/courses/sabd2526/...",
    "expected_sha1": "17be276b72bd987e72598b0ea4907c3b19350606"
  },
  "storage_raw": { "type": "HDFS", "path": "/data/raw" },
  "storage_preprocessed": {
    "type": "S3",
    "bucket": "spark-flight-analysis",
    "path": "data/conv"
  },
  "processing": { "optimization_strategy": "PARTITION_PRUNING" },
  "callback": {
    "run_id": "run_123",
    "variable_key": "nifi_done_run_123",
    "url": "http://.../variables/nifi_done_run_123",
    "method": "PATCH",
    "headers": {
      "Authorization": "Bearer eyJhbG...",
      "Content-Type": "application/json"
    }
  }
}
```



NiFi Ingestion Pipeline: Download, Decompressione e Routing

- **Estrazione e Validazione:**



- Download automatico del dataset compresso dall'origine.
- Controllo di integrità tramite `CryptographicHashContent`.

- **Decompressione e Filtraggio:**

- Spacchettamento via `CompressContent` e `UnpackContent`.
- Ispezione e routing selettivo dei soli CSV d'interesse.



- **Routing dei File:**

- **Ramo Raw:** Salvataggio as-is per garanzia del dato originale.
- **Ramo Preprocessing:** Inoltro dei file d'interesse alla trasformazione.



NiFi Ingestion Pipeline: Preprocessing

- **Sanitizzazione** - ScriptedTransformRecord:
 - Se esiste una causa di ritardo positiva, imposta le altre nulle a 0.
 - Normalizzazione a 0 delle componenti di ritardo negative.
- **Data Cleaning** - QueryRecord:
 - Taglio dei record con chiavi primarie nulle o dati temporali mancanti.
 - Eliminazione dei voli cancellati con orario di partenza presente.
 - Scarto dei record con delay negativo e componenti di ritardo positive.
- **Strategie di Conversione:**
 - **Partition Pruning:** PartitionRecord converte in Parquet partizionando per chiavi temporali e carrier.
 - **Predicate Pushdown:** MergeRecord compatta e converte in un singolo file Parquet.




NiFi Ingestion Pipeline: Storage Finale e Callback ad Airflow

- **Storage Distribuito:** Scrittura dei file Parquet ottimizzati in HDFS o S3.
- **Notifica di Completamento:**
 - Chiamata HTTP PATCH via InvokeHTTP alle API di Airflow.
 - L'url di callback viene fornito nel payload di attivazione.

Payload JSON

```
{  
  "key": "${airflow.callback.variable_key}",  
  "value": "true"  
}
```



Configurazione a Start-Time e Design Pattern Java

Parametrizzazione a Start-Time:

- **Configurazione senza ricompilazione:** Gestione via YAML tramite `ApplicationConfig` con override da CLI.
- **Selezione del Backend:** Scelta a runtime dell'astrazione (*RDD*, *DataFrame*, *SQL*) e delle strategie di calcolo (KLL o T-Digest).

Design Pattern Java:

- **Template Method:** `BaseQuery` standardizza e unifica l'intero ciclo di vita del job Spark.
- **Factory e Repository:** `FlightRepositoryFactory` gestisce il polimorfismo, astraendo le connessioni ai database.
- **Singleton:** `PerformanceMetrics` come punto unico e centralizzato di raccolta delle metriche di esecuzione.

Terminale - Spark Submit

```
spark-submit
  --master <SPARK_URI>
  --class FlightAnalysisApp
  <HDFS_URI>/<HDFS_JAR_PATH>
  --query "<SELECTED_QUERY>"
  --backend "<SPARK_BACKEND>"
  --config "<CONFIG_FILE>"
  --input-type "<IN_TYPE>"
  --output-type "<OUT_TYPE>"
  --metrics-type "<M_TYPE>"
```


Query 1 - Analisi Mensile Performance: RDD API

Obiettivo

Aggregare i voli 2025 di AA e DL su base mensile. Calcolare min, max, media di departure delay solo sui voli non cancellati e il tasso di cancellazione dei voli

RDD API

```
flights.mapToPair(v -> ([v.airline, v.month], v))
  .aggregateByKey(
    zeroValue: [sumDelay: 0, maxDelay: -inf, minDelay: +inf, notCancelled: 0, total: 0],
    combiner: (acc, v) -> {
      acc.total += 1
      if !v.cancelled then
        acc.sumDelay += v.dep_delay
        acc.maxDelay = MAX(acc.maxDelay, v.dep_delay)
        acc.minDelay = MIN(acc.minDelay, v.dep_delay)
        acc.notCancelled += 1
      return acc
    },
    reducer: (a1, a2) -> {
      a1.sumDelay += a2.sumDelay
      a1.maxDelay = MAX(a1.maxDelay, a2.maxDelay)
      a1.minDelay = MIN(a1.minDelay, a2.minDelay)
      a1.notCancelled += a2.notCancelled
      a1.total += a2.total
      return a1
    })
  .map(tuple -> {
    mean = tuple.sumDelay / tuple.notCancelled
    cancRate = (tuple.total - tuple.notCancelled) / tuple.total * 100
    return Row(tuple.month, tuple.airline, media, tuple.minDelay, tuple.maxDelay, cancRate)
  })
```

Query 1 - Analisi Mensile Performance: High-Level API

Obiettivo

Aggregare i voli 2025 di AA e DL su base mensile. Calcolare min, max, media di departure delay solo sui voli non cancellati e il tasso di cancellazione dei voli

DataFrame API

```
flights
  .groupBy("MONTH", "OP_UNIQUE_CARRIER")
  .agg(
    avg(when(col("CANCELLED") == 0,
              col("DEP_DELAY"))).as("mean"),
    min(when(col("CANCELLED") == 0,
              col("DEP_DELAY"))).as("min"),
    max(when(col("CANCELLED") == 0,
              col("DEP_DELAY"))).as("max"),
    sum(when(col("CANCELLED") == 0,
              col("DEP_DELAY"))).as("sum")
  )
  .withColumnRenamed("MONTH", "month")
  .withColumnRenamed("OP_UNIQUE_CARRIER", "airline")
```

Spark SQL API

```
SELECT
  MONTH                AS month,
  OP_UNIQUE_CARRIER AS airline,

  AVG(CASE WHEN CANCELLED == 0 THEN DEP_DELAY END) AS 'mean',
  MIN(CASE WHEN CANCELLED == 0 THEN DEP_DELAY END) AS 'min',
  MAX(CASE WHEN CANCELLED == 0 THEN DEP_DELAY END) AS 'max',

  (SUM(CANCELLED) / COUNT(*)) * 100 AS 'cancel_rate'

FROM flights
GROUP BY MONTH, OP_UNIQUE_CARRIER
```

Query 2 - Top 10 Ritardi e Scomposizione Cause: RDD API

Obiettivo

Classifica delle prime 10 compagnie per ritardo medio all'arrivo decrescente, considerando solo i voli non cancellati/deviati e con conteggio maggiore o uguale a 500, mostrando anche l'incidenza media di ciascuna causa di ritardo.

RDD API

```
validFlights = flights.filter(f -> getSafe(f, CANCELLED) == 0 && getSafe(f, DIVERTED) == 0)
reducedRDD = validFlights.mapToPair(f -> (f.getString(OP_UNIQUE_CARRIER), f))
  .aggregateByKey(
    zeroValue: new double[7], // [0: Count, 1: Arr, 2: Carrier, 3: Weather, 4: NAS, 5: Security, 6: Late]
    combiner: (acc, f) -> {
      acc.count += 1.0
      acc.carrier += getSafe(f, CARRIER_DELAY)
      acc.nas += getSafe(f, NAS_DELAY)
      acc.late += getSafe(f, LATE_AIRCRAFT_DELAY)
      acc.arr += getSafe(f, ARR_DELAY)
      acc.weather += getSafe(f, WEATHER_DELAY)
      acc.security += getSafe(f, SECURITY_DELAY)
      return acc
    },
    reducer: (acc1, acc2) -> {
      for (int i=0; i<7; i++) acc1[i] += acc2[i]
      return acc1
    })
processedRDD = reducedRDD.filter(t -> t.del.count >= 500.0)
  .map(t -> {
    double c = t.del.count
    return Row(t.carrier, c, t.del.arr/c, t.del.carrier/c, t.del.weather/c, t.del.nas/c, t.del.security/c,
      t.del.late/c)
  })
sortedRDD = processedRDD.sortBy(r -> r.arrDelay, false, partitions)
top10RDD = sortedRDD.zipWithIndex().filter(t -> t.position < 10).map(t -> t.row).coalesce(1)
```

Query 2 - Top 10 Ritardi e Scomposizione Cause: High-Level APIs

Obiettivo

Classifica delle prime 10 compagnie per ritardo medio all'arrivo decrescente, considerando solo i voli non cancellati/deviati e con conteggio maggiore o uguale a 500, mostrando anche l'incidenza media di ciascuna causa di ritardo.

DataFrame API

```
flights
  .filter(col("CANCELLED").equalTo(0)
        .and(col("DIVERTED").equalTo(0)))
  .groupBy("OP_UNIQUE_CARRIER")
  .agg(
    count("*").as("num_flights"),
    avg(coalesce(col("ARR_DELAY",
      lit(0))).as("arrdelay_mean"),
    avg(coalesce(col("CARRIER_DELAY",
      lit(0))).as("carrier_mean"),
    avg(coalesce(col("WEATHER_DELAY",
      lit(0))).as("weather_mean"),
    avg(coalesce(col("NAS_DELAY", lit(0))).as("nas_mean"),
    avg(coalesce(col("SECURITY_DELAY",
      lit(0))).as("security_mean"),
    avg(coalesce(col("LATE_AIRCRAFT_DELAY",
      lit(0))).as("late_aircraft_mean")
  )
  .withColumnRenamed("OP_UNIQUE_CARRIER", "carrier")
  .filter(col("num_flights").geq(500))
  .orderBy(col("arrdelay_mean").desc())
  .limit(10)
```

Spark SQL API

```
SELECT
  OP_UNIQUE_CARRIER AS carrier,
  COUNT(*)           AS num_flights,

  AVG(COALESCE(ARR_DELAY, 0))      AS arrdelay_mean,
  AVG(COALESCE(CARRIER_DELAY, 0)) AS carrier_delay_mean,
  AVG(COALESCE(WEATHER_DELAY, 0))  AS weather_delay_mean,
  AVG(COALESCE(NAS_DELAY, 0))      AS nas_delay_mean,
  AVG(COALESCE(SECURITY_DELAY, 0)) AS
    security_delay_mean,
  AVG(COALESCE(LATE_AIRCRAFT_DELAY, 0)) AS
    late_aircraft_delay_mean

FROM flights
WHERE CANCELLED = 0 AND DIVERTED = 0

GROUP BY OP_UNIQUE_CARRIER
HAVING num_flights >= 500

ORDER BY arrdelay_mean DESC
LIMIT 10
```

Query 3 - Percentili Orari e Min/Max Globali: RDD API

Obiettivo

Calcolo dei percentili 25, 50, 75 e 90 del departure delay per fascia oraria tramite algoritmi di sketch e calcolo di min/max globali.

RDD API

```
validFlights = flights.filter(f -> getSafe(f, CANCELLED) == 0 && !f.isNullAt(DEP_DELAY)).cache()
// Pipeline 1: Calcolo Percentili Orari tramite Sketch distribuiti
PercentileSketch sketch = PercentileSketch.from(config.getPercentileAlgorithm())
hourlyRows = validFlights.filter(f -> !f.isNullAt(CRS_DEP_TIME))
    .mapToPair(f -> ( (f.getString(CARRIER), (f.getInt(CRS_DEP_TIME) / 100) % 24), getSafe(f, DEP_DELAY) ))
    .combineByKey(sketch::init, sketch::update, sketch::merge)
    .map(t -> {
        double[] q = sketch.getQuantiles(t.percentile, 0.25, 0.50, 0.75, 0.90)
        return Row(t.key.carrier, t.key.hour, q.p25, q.p50, q.p75, q.p90)
    })
// Pipeline 2: Aggregazione Globale Min/Max per Compagnia
globalRows = validFlights.mapToPair(f -> (f.getString(CARRIER), f))
    .aggregateByKey(
        zeroValue: new double[]{+inf, -inf}, // [0: minDelay, 1: maxDelay]
        combiner: (acc, f) -> {
            double d = getSafe(f, DEP_DELAY)
            acc.min = MIN(acc[0], d)          acc.max = MAX(acc[1], d)
            return acc
        },
        reducer: (a1, a2) -> {
            a1.min = MIN(a1.min, a2.min)      a1.max = MAX(a1.max, a2.max)
            return a1
        })
    .map(t -> Row(t.carrier, t.res.min, t.res.max))
```

Query 3 - Percentili Orari e Min/Max Globali: High-Level APIs

Obiettivo

Calcolo dei percentili 25, 50, 75 e 90 del departure delay per fascia oraria tramite algoritmi di sketch e calcolo di min/max globali.

DataFrame API

```
validFlights = flights.filter(col("CANCELLED").equalTo(0))
                        .cache()

// Pipeline 1: Percentili orari approssimati
hourlyStats = validFlights
  .withColumn("hour",
    col("CRS_DEP_TIME").divide(100).cast("int"))
  .groupBy("OP_UNIQUE_CARRIER", "hour")
  .agg(
    expr("percentile_approx(DEP_DELAY, 0.25)").as("p25"),
    expr("percentile_approx(DEP_DELAY, 0.50)").as("p50"),
    expr("percentile_approx(DEP_DELAY, 0.75)").as("p75"),
    expr("percentile_approx(DEP_DELAY, 0.90)").as("p90"))
  .withColumnRenamed("OP_UNIQUE_CARRIER", "airline")

// Pipeline 2: Min/Max assoluti
globalMinMax = validFlights
  .groupBy("OP_UNIQUE_CARRIER")
  .agg(
    min("DEP_DELAY").as("min_delay"),
    max("DEP_DELAY").as("max_delay"))
  .withColumnRenamed("OP_UNIQUE_CARRIER", "airline")
```

Spark SQL API

```
flights.filter("CANCELLED = 0")
        .createOrReplaceTempView("validFlights");

// Pipeline 1: Percentili orari approssimati
SELECT
  OP_UNIQUE_CARRIER AS airline,
  CAST(CRS_DEP_TIME / 100 AS INT) AS hour,
  percentile_approx(DEP_DELAY, 0.25) AS p25,
  percentile_approx(DEP_DELAY, 0.50) AS p50,
  percentile_approx(DEP_DELAY, 0.75) AS p75,
  percentile_approx(DEP_DELAY, 0.90) AS p90
FROM validFlights
WHERE CANCELLED = 0
GROUP BY OP_UNIQUE_CARRIER, hour;

// Pipeline 2: Min/Max assoluti
SELECT
  OP_UNIQUE_CARRIER AS airline,
  MIN(DEP_DELAY) AS min_delay,
  MAX(DEP_DELAY) AS max_delay
FROM validFlights
GROUP BY OP_UNIQUE_CARRIER;
```

Query 3 - Percentili Orari e Min/Max Globali: T-Digest vs KLL Sketch

Obiettivo

Calcolo dei percentili 25, 50, 75 e 90 del departure delay per fascia oraria tramite algoritmi di sketch e calcolo di min/max globali.

T-Digest

```
final int COMPRESSION = 100;

// Inizializzazione buffer
MergingDigest digest = new MergingDigest(100.0);

// Update / Merge via ByteBuffer
MergingDigest.fromBytes(ByteBuffer.wrap(state));

// Compattazione in byte array
ByteBuffer buf = ByteBuffer.allocate(
    digest.smallBufferSize()
);

digest.asSmallBytes(buf);
return buf.array();
```

$$\epsilon_{avg} \approx \frac{\pi}{2\delta} \xrightarrow{\delta=100} \frac{\pi}{200} \approx 1.57\%$$
$$\epsilon_{worst} \approx \frac{3}{\delta} \xrightarrow{\delta=100} \frac{3}{100} = 3.0\%$$

KLL Sketch

```
// Allocazione nativa in Heap
KllDoublesSketch.newHeapInstance();

// Ricostruzione stato tramite Memory
KllDoublesSketch.heapify(Memory.wrap(state));

// Export diretto nativo ultra-veloce
return sketch.toByteArray();

// Estrazione quantili con criterio inclusivo
sketch.getQuantile(q,
    QuantileSearchCriteria.INCLUSIVE);
```

$$\epsilon_{avg} \approx \frac{1.4}{k} \xrightarrow{k=200} \frac{1.4}{200} = 0.7\%$$
$$\epsilon_{worst} \approx \frac{3.3}{k} \xrightarrow{k=200} \frac{3.3}{200} = 1.65\%$$

Query 4 - Airline Clustering: ML Pipeline

Obiettivo

Individuare gruppi di compagnie con comportamenti simili su metriche aggregate, standardizzando lo spazio multivariato ed applicando l'algoritmo K-Means.

Silhouette Analysis e K-Means

```
ClusteringEvaluator evaluator = new ClusteringEvaluator()
    .setFeaturesCol("features")
    .setPredictionCol("prediction")
    .setMetricName("silhouette");
int bestK = 2; double bestScore = -1.0;
for (int k = 2; k <= 5; k++) {
    KMeans km = new KMeans().setK(k)
        .setSeed(42L).setInitMode("k-means||");
    KMeansModel m = km.fit(scaledData);
    double score =
        evaluator.evaluate(m.transform(scaledData));
    if (score > bestScore) {
        bestScore = score; bestK = k; }
}
KMeansModel modelFinal = new KMeans()
    .setK(bestK).setSeed(42L).fit(scaledData);
```

Proiezione PCA per Visualizzazione

```
PCA pca = new PCA()
    .setInputCol("features")
    .setOutputCol("pca_features")
    .setK(2);

PCAModel pcaModel = pca.fit(finalPredictions);

// Espansione del vettore nei componenti x e y
Dataset<Row> finalOutput = appendPcaColumns(
    pcaModel.transform(finalPredictions), ...
);
```


Spark: Misurazione delle Metriche

Event-Driven Listening

- JobTimerListener estende SparkListener.
- Intercettazione asincrona degli eventi del ciclo di esecuzione di Spark.

Tracciamento Granulare

- **Job e Stage Level:** Isolamento delle durate pure dei singoli stage e job.
- **I/O e Network Balance:** Misurazione sia dei dati di I/O che dei dati scambiati durante le fasi di Shuffle.
- **Worker Profiling:** Misurazione per singolo Executor per individuare fenomeni di Data Skew.

JobTimerListener

```
@Override
public void onStageCompleted(SparkListenerStageCompleted
    sc) {
    TaskMetrics tm = sc.stageInfo().taskMetrics();
    long duration = System.currentTimeMillis() - start;
    long gcTime = tm.jvmGCTime();
    long bytesRead = tm.inputMetrics().bytesRead();
    long shuffleRead =
        tm.shuffleReadMetrics().totalBytesRead();
    ...


    PerformanceMetrics.getInstance()
        .addStageMetrics(...);
}

@Override
public void onTaskEnd(SparkListenerTaskEnd te) {
    String executorId = te.taskInfo().executorId();
    TaskMetrics tm = te.stageInfo().taskMetrics();
    long bytesRead = tm.inputMetrics().bytesRead();
    long serializeTime = tm.resultSerializationTime();
    ...

    PerformanceMetrics.getInstance()
        .addExecutorMetrics(...);
}
```

Orchestrazione End-to-End: flight_analysis

- **Obiettivo del Workflow:** Eseguire l'intera pipeline, dalla fase di Ingestion a quella di Processamento.
- **Workflow Operativo:**
 - `route_start`: Valutazione della modalità operativa per il branching del flusso: *Ingest*, *Execution*, *Both*.
 - `trigger_nifi_backend`: Generazione del payload JSON e iniezione dei metadati via chiamata REST a NiFi.
 - `wait_nifi_done`: Sincronizzazione asincrona tramite Sensor (polling su variabile aggiornata da NiFi via callback).
 - `prepare_spark_args`: Mapping dei parametri del DAG in argomenti CLI per il job Spark.
 - `spark_execution`: Sottomissione del job Spark tramite LivyOperator in modalità client.



Orchestrazione del Benchmarking: EC2 vs EMR

- **Obiettivo:** Valutazione sistematica di tutte le combinazioni sugli ambienti di deployment.
- Creazione dinamica di una pipeline sequenziale, garantendo l'isolamento delle risorse per ogni job Spark.

Cluster Self-Hosted

```
spark_task = LivyOperator(  
    task_id=task_id,  
    livy_conn_id="livy_default",  
    file=JAR_PATH,  
    class_name=JAR_CLASS,  
    args=[  
        "--query", query,  
        "--backend", backend,  
        "--config", "{{ params.config_file }}",  
        "--input-type", "{{ params.input_type }}",  
        "--output-type", "{{ params.output_type }}",  
        "--metrics-type", "{{ params.metrics_type }}"  
    ],  
    name=f"benchmark-{{query}}-{{backend}}",  
    polling_interval=5  
)
```

AWS EMR


```
spark_step = {  
    "Name": step_name,  
    "ActionOnFailure": "CONTINUE",  
    "HadoopJarStep": {  
        "Jar": "command-runner.jar",  
        "Args": [  
            "spark-submit", "--deploy-mode", "client",  
            "--class", JAR_CLASS, JAR_PATH,  
            "--query", query, ...  
        ],  
    },  
}  
  
add_step = EmrAddStepsOperator(  
    task_id=tid,  
    job_flow_id="{{ params.job_flow_id }}",  
    aws_conn_id="aws_default",  
    steps=[spark_step]  
)  
  
watch_step = EmrStepSensor(  
    task_id=task_id,  
    job_flow_id="{{ params.job_flow_id }}",  
    step_id=f"{{{ ti.xcom_pull(task_ids='{tid}')[0] }}}",  
    aws_conn_id="aws_default",  
    poke_interval=30  
)
```

Metodologia di Benchmarking: EC2 Deployment

Ogni combinazione (Query $\times$ Backend $\times$ Ottimizzazione I/O) è stata eseguita 5 volte per garantire la stabilità delle misurazioni.

Deploy On-promise EC2:

- Airflow e Livy - (1x t3.medium)
- NiFi - 1x t3.small
- Grafana e Redis Stack - 1x t3.small
- Databases - 1x t3.small
- Master (HDFS e Spark) - 1x t3.small
- Workers (HDFS e Spark) - 3x t3.small




Metodologia di Benchmarking: AWS EMR Deployment

Ogni combinazione (Query $\times$ Backend $\times$ Ottimizzazione I/O) è stata eseguita 5 volte per garantire la stabilità delle misurazioni.

Deploy Managed AWS EMR:

- Airflow e Livy - (1x t3.medium)
- NiFi - 1x t3.small
- Grafana e Redis Stack - 1x t3.small
- Databases - 1x t3.small
- Master Node - 1x m6g.xlarge
- Core Nodes - 3x m6g.xlarge



Confronto API: RDD vs DataFrame vs SQL

Aggregazioni Massive: Q1 e Q2


- DataFrame e SQL mostrano mediane temporali inferiori e una dispersione contratta in ogni ambiente.

Spark Execution Time Distribution



Distribuzione tempi Q1 con partition pruning su EMR

Spark Execution Time Distribution




Distribuzione tempi Q2 con partition pruning su EMR

Approssimazione Percentili: Q3


- **Self-Hosted EC2:** RDD con KLL risulta mediamente più veloce.
- **Managed su EMR:** EMR azzerava il vantaggio di RDD e DataFrame riprende il primato.

Spark Execution Time Distribution



Distribuzione tempi Q3 con partition pruning e KLL su EC2

Spark Execution Time Distribution



Distribuzione tempi Q3 con partition pruning e KLL su EMR

Ottimizzazione I/O: Pruning vs Pushdown

- **Predicate Pushdown:** Genera un volume di lettura superiore e tende a sovraccaricare singoli nodi.



Sbilanciamento I/O con predicate pushdown su EC2 nella Q1



Sbilanciamento I/O con predicate pushdown su EC2 nella Q2

- **Partition Pruning:** Esclude i file a livello di file system, diminuendo il *Read Skew* fra i nodi.




Sbilanciamento I/O con partition pruning su EC2 nella Q1




Sbilanciamento I/O con partition pruning su EC2 nella Q2

Overhead Infrastrutturale: EC2 vs EMR

- EMR riduce sensibilmente l'overhead di sistema, con un rapporto di *Execution Time* vs *Wall-Clock Time* più favorevole rispetto a EC2.



Overhead di sistema con predicate pushdown su EC2 nella Q1




Overhead di sistema con predicate pushdown su EMR nella Q1

Confronto Sketch: KLL vs T-Digest

KLL Sketch


- Richiede un maggiore impiego di memoria per preservare la struttura a piramide dei livelli.

Shuffle Intensity: Internal Data Exchange ⓘ



Volume di Shuffle Read su EC2 per KLL con partition pruning

Spark Execution Time Distribution ⓘ




Tempo di esecuzione su EC2 per KLL con partition pruning

T-Digest


- Altamente compatto in termini di memoria, poiché memorizza unicamente i centroidi.

Shuffle Intensity: Internal Data Exchange ⓘ



Volume di Shuffle Read su EC2 per T-Digest con partition pruning

Spark Execution Time Distribution ⓘ



Tempo di esecuzione su EC2 per T-Digest con partition pruning


Risultati Analitici: Q3 - Percentili Orari

Dinamiche Operative

- Le performance degradano sistematicamente nelle fasce serali probabilmente a causa della propagazione a catena dei ritardi.

Confronto Algoritmico

- Convergenza analitica dei risultati tra le euristiche.
- La selezione dipende dai vincoli non funzionali.



Risultati Analitici: Q4 - Airline Clustering


Profilazione delle Compagnie

- **C0 - Inefficienza:** AA, B6, 00, F9, OH. Forte propagazione a catena dei ritardi e picchi di cancellazioni ($> 6\%$).
- **C1 - Resilienza:** G4. Forti ritardi per cause esterne, ma altissimo completamento voli (canc. 0.6%).
- **C2 - Virtuosi:** UA, NK, DL, MQ, HA, YX, AS, WS. Stabilità massima e forte capacità di recupero tempo in volo.


Q4 — Multi-dimensional Centroid Profiles



Q4 — Latent Performance Clusters (PCA Projection)




Q4 — Population Distribution by Cluster



Risultati Analitici: Q1 e Q2 - Performance e Cause



Q1: Performance Mensili

- DL:** Miglioramento costante. Il ritardo scende e le cancellazioni si stabilizzano sotto lo 0.5%.
- AA:** Degrado progressivo. Il ritardo sale con un tasso di cancellazione ~ 1.4%.



Q2: Decomposizione dei Ritardi

- OH:** Peggior vettore per ritardo in arrivo. Forte incapacità di assorbire i ritardi pregressi (*Late Aircraft delay*).
- UA:** Altamente virtuoso, ma fortemente esposto alla congestione del traffico aereo (*NAS delay*).



Conclusioni

- **Ecosistema Enterprise-Ready:** L'orchestrazione asincrona con Airflow combinata alla modularità di Spark e NiFi garantisce scalabilità e robustezza.
- **Ottimizzazione dell'I/O:** L'uso congiunto del formato colonnare Parquet e del Partition Pruning diminuisce l'overhead di lettura sul file system distribuito.
- **Analitica Avanzata e Sostenibile:** L'integrazione di Quantile Sketches e Model Selection automatizzato decodifica dinamiche complesse mantenendo costi computazionali accettabili.

Sviluppi Futuri

- **Architettura Streaming:** Integrazione di Apache Kafka e Spark Structured Streaming per l'acquisizione della telemetria di volo in tempo reale.
- **Predictive Analytics on-the-fly:** Sfruttare i centroidi dei modelli ML pre-addestrati per classificare la stabilità della rete e prevedere anomalie in tempo reale.

Grazie per l'attenzione



TOR VERGATA
UNIVERSITÀ DEGLI STUDI DI ROMA