

Sky Analytics Engine

Analisi batch e Metriche del Traffico Aereo

Flavio Simonelli Francesco Masci

Corso Architettura e Sistemi per Big Data
Corso di Laurea Magistrale in Ingegneria Informatica
Università di Roma "Tor Vergata"


12 Giugno 2026




TOR VERGATA
UNIVERSITÀ DEGLI STUDI DI ROMA

- 1 Big Data Stack
- 2 Flow Diagram
- 3 Sequence Diagram
- 4 Extraction & Ingestion Layer
- 5 Deployment


Big Data Stack



Flow Diagram



Sequence Diagram




NiFi Ingestion Pipeline: Approccio Data-Driven

- **Design Data-Driven:** Pipeline stateless configurata dinamicamente tramite payload JSON iniettato all'avvio (EvaluateJsonPath).
- **Parametri chiave del JSON:**
 - `experiment.id`: Identificativo univoco del job.
 - `ingestion`: Parametri sorgente (URL HTTP, SHA-1 atteso).
 - `storage`: Percorsi dinamici per dati Raw e Preprocessed (HDFS/S3).
 - `processing.strategy`: Scelta della strategia di ottimizzazione (PARTITION PRUNING o PREDICATE PUSHDOWN).
 - `callback`: Configurazione per la notifica finale ad Airflow.

Ingestion, Sicurezza e Gateway

- **Estrazione:** Ricezione e spaccettamento degli archivi (UnpackContent).
- **Validazione SHA-1:**
 - Controllo di integrità crittografica sui file estratti.
 - Confronto hash atteso vs calcolato (CryptographicHashContent).
 - Routing degli errori per isolare dati corrotti.
- **Gateway & Biforcazione:**
 - **Ramo Raw:** Salvataggio as-is per garanzia del dato originale.
 - **Ramo Preprocessing:** Inoltro dei record validati alla trasformazione.



Preprocessing e Ottimizzazione in Parquet


- **Operatori NiFi per la Trasformazione:**

- QueryRecord/UpdateRecord: Filtraggio, casting e normalizzazione.
- LookupRecord: Arricchimento dei dati via file dizionario.
- MergeRecord: Prevenzione dello "Small Files Problem".

- **Target Parquet:** Conversione con schema enforcement (Avro).


- **Strategie di Ottimizzazione:**

- **Partition Pruning:** Generazione dinamica dei path (UpdateAttribute).
- **Predicate Pushdown:** Ottimizzazione dei metadati per Spark.




Storage Finale e Handover ad Airflow

- **Storage Distribuito:** Scrittura dei file Parquet ottimizzati in HDFS o S3.
- **Notifica di Completamento:**
 - Chiamata REST via InvokeHTTP (PATCH/POST) alle API di Airflow.
 - Handover del payload aggiornato con lo stato dell'elaborazione.
- **Orchestrazione Analitica:** Sblocco automatico dei successivi job Spark in base alla strategia scelta.



EC2 Deployment



EMR Deployment

[Immagine in arrivo]