

Sky Analytics Engine

Analisi batch e Metriche del Traffico Aereo

Flavio Simonelli Francesco Masci

Corso Architettura e Sistemi per Big Data
Corso di Laurea Magistrale in Ingegneria Informatica
Università di Roma "Tor Vergata"


12 Giugno 2026




TOR VERGATA
UNIVERSITÀ DEGLI STUDI DI ROMA

- 1 Big Data Stack
- 2 Flow Diagram
- 3 Sequence Diagram
- 4 Extraction & Ingestion Layer
- 5 Deployment


Big Data Stack



Flow Diagram



Sequence Diagram



NiFi Ingestion Pipeline: Approccio Data-Driven


- **Design Data-Driven:** Pipeline stateless configurata dinamicamente tramite payload JSON iniettato all'avvio.
- **Ingestion & Validazione:** `HandleHttpRequest` espone l'endpoint REST per l'avvio da Airflow, mentre `ValidateJson` esegue un controllo strutturale con schema rigoroso.
- **Propagazione del Dato:** `EvaluateJsonPath` mappa le chiavi JSON in Attributi del `FlowFile`, guidando in modo stateless il routing e le decisioni future tramite metadati nativi.

Payload JSON

```
{
  "job_id": "FLIGHT_INGEST_run_123",
  "storage_raw": {
    "type": "HDFS",
    "path": "/data/raw"
  },
  "storage_preprocessed": {
    "type": "S3",
    "bucket": "spark-flight-analysis",
    "path": "data/conv"
  },
  "processing": {
    "optimization_strategy": "PARTITION..."
  },
  "callback": {
    "url": "http://airflow.../variables/v",
    "method": "PATCH",
    "headers": {
      "Authorization": "Bearer eyJhbG..."
    }
  }
}
```


Ingestion, Sicurezza e Gateway

- **Estrazione:** Ricezione e spaccettamento degli archivi (UnpackContent).
- **Validazione SHA-1:**
 - Controllo di integrità crittografica sui file estratti.
 - Confronto hash atteso vs calcolato (CryptographicHashContent).
 - Routing degli errori per isolare dati corrotti.
- **Gateway & Biforcazione:**
 - **Ramo Raw:** Salvataggio as-is per garanzia del dato originale.
 - **Ramo Preprocessing:** Inoltro dei record validati alla trasformazione.




Preprocessing e Ottimizzazione in Parquet

- **Operatori NiFi per la Trasformazione:**
 - QueryRecord/UpdateRecord: Filtraggio, casting e normalizzazione.
 - LookupRecord: Arricchimento dei dati via file dizionario.
 - MergeRecord: Prevenzione dello "Small Files Problem".
- **Target Parquet:** Conversione con schema enforcement (Avro).
- **Strategie di Ottimizzazione:**
 - **Partition Pruning:** Generazione dinamica dei path (UpdateAttribute).
 - **Predicate Pushdown:** Ottimizzazione dei metadati per Spark.




Storage Finale e Handover ad Airflow

- **Storage Distribuito:** Scrittura dei file Parquet ottimizzati in HDFS o S3.
- **Notifica di Completamento:**
 - Chiamata REST via InvokeHTTP (PATCH/POST) alle API di Airflow.
 - Handover del payload aggiornato con lo stato dell'elaborazione.
- **Orchestrazione Analitica:** Sblocco automatico dei successivi job Spark in base alla strategia scelta.



EC2 Deployment



EMR Deployment

[Immagine in arrivo]