

Sky Analytics Engine

Analisi batch e Metriche del Traffico Aereo

Flavio Simonelli Francesco Masci

Corso Architettura e Sistemi per Big Data
Corso di Laurea Magistrale in Ingegneria Informatica
Università di Roma "Tor Vergata"


12 Giugno 2026




TOR VERGATA
UNIVERSITÀ DEGLI STUDI DI ROMA

- 1 Big Data Stack
- 2 Flow Diagram
- 3 Deployment
- 4 Data Extraction & Ingestion


Big Data Stack



Flow Diagram



EC2 Deployment



EMR Deployment

[Immagine in arrivo]

Architettura Event-Driven della Pipeline NiFi

- **Panoramica:** Il flusso SAE_Ingestion_Pipeline è modulare e orchestrato esternamente tramite Apache Airflow.
- **Innesco Dinamico:** La pipeline è data-driven. Si avvia con un payload JSON da cui estrae configurazioni vitali:
 - Run ID ed Expected SHA-1
 - Percorsi e tipologia di storage
 - URL di callback
- **Ruolo:** NiFi funge da middleware intelligente tra la sorgente dei dati e il Data Lake.

- **Unpacking & Integrità:** I dati compressi vengono scompattati. Un check crittografico confronta l'hash SHA-1 con quello atteso per prevenire corruzioni.
- **Routing Logico:** Separazione del flusso principale (voli) dai file di supporto (dizionari) per evitare congestioni.
- **Filtraggio Preliminare:** Selezione dei soli file target (es. file `ONTIME_REPORTING`) scartando i dati non pertinenti.

Biforcazione: Salvataggio Raw e Inoltro al Processing

- **Lo Split Logico:** Dopo la validazione e il filtraggio, il flusso si sdoppia seguendo il pattern Data Lake.
- **Percorso A - Raw Data Storage:** I dati grezzi vengono salvati. Il sistema di destinazione (HDFS o S3) è deciso dinamicamente in base ai parametri del payload iniziale.
- **Percorso B - Verso la Trasformazione:** Una copia viene instradata verso i moduli successivi per il filtraggio a livello di record e la conversione per l'analisi.

Trasformazione e Ottimizzazione in Parquet

- **Merge & Compattazione:** I dati CSV vengono accorpati per prevenire lo "Small Files Problem" penalizzante nei sistemi distribuiti.
- **Conversione Parquet:** Conversione dei record nel formato colonnare Parquet, riducendo lo spazio e velocizzando le query analitiche.
- **Preparazione per Spark:** Iniezione di attributi di ottimizzazione (PARTITION_PRUNING, PREDICATE_PUSHDOWN) per guidare l'engine di calcolo.

Storage Finale e Chiusura del Ciclo

- **Salvataggio Processed Data:** I file Parquet vengono salvati nello strato Silver del Data Lake, pronti per l'analisi.
- **Chiusura (Finish_AirFlow):** NiFi notifica il completamento dell'ingestion tramite chiamata HTTP all'URL di callback.
- **Orchestrazione:** Il segnale di successo (o errore) sblocca Airflow, permettendo l'avvio automatico dei successivi job di calcolo distribuito (Spark).