



TOR VERGATA
UNIVERSITÀ DEGLI STUDI DI ROMA

Sky Analytics Engine

Analisi batch e Metriche del Traffico Aereo

Flavio Simonelli Francesco Masci

Corso Architettura e Sistemi per Big Data
Corso di Laurea Magistrale in Ingegneria Informatica
Università di Roma "Tor Vergata"

12 Giugno 2026

Architettura e Flusso

Extraction & Ingestion Layer

Computation Layer


Airflow Orchestration

Valutazione Sperimentale


Risultati Analitici

Architettura e Flusso

Big Data Stack & Flow Diagram




Vista Statica: Componenti del Big Data Stack



Vista Dinamica: Flusso di interazione dei componenti

Sequence Diagram




Extraction & Ingestion Layer

NiFi Ingestion Pipeline: REST Trigger

- **Design Data-Driven:** Pipeline stateless configurata dinamicamente in base al payload JSON iniettato all'avvio da Airflow.
- **Ingestion & Validazione:**
 - **HandleHttpRequest:** espone l'endpoint REST per intercettare l'avvio.
 - **ValidateJson:** esegue il controllo strutturale rigoroso tramite JSON Schema.
- **Propagazione del Dato:**
 - **EvaluateJsonPath:** estrae e mappa le chiavi JSON in Attributi del FlowFile.
 - I metadati nativi guidano il routing successivo in logica completamente stateless.

Payload JSON

```
{
  "job_id": "FLIGHT_INGEST_run_123",
  "ingestion": {
    "source_type": "HTTP",
    "http_url": "http://www.ce.uniroma2.it/courses/sabd2526/...",
    "expected_sha1": "17be276b72bd987e72598b0ea4907c3b19350606"
  },
  "storage_raw": { "type": "HDFS", "path": "/data/raw" },
  "storage_preprocessed": {
    "type": "S3",
    "bucket": "spark-flight-analysis",
    "path": "data/conv"
  },
  "processing": { "optimization_strategy": "PARTITION_PRUNING" },
  "callback": {
    "run_id": "run_123",
    "variable_key": "nifi_done_run_123",
    "url": "http://.../variables/nifi_done_run_123",
    "method": "PATCH",
    "headers": {
      "Authorization": "Bearer eyJhbG...",
      "Content-Type": "application/json"
    }
  }
}
```



NiFi Ingestion Pipeline: Download, Decompressione e Routing

- **Estrazione e Validazione:**



- Download automatico del dataset compresso dall'origine.
- Controllo di integrità tramite `CryptographicHashContent`.

- **Decompressione e Filtraggio:**

- Spacchettamento via `CompressContent` e `UnpackContent`.
- Ispezione e routing selettivo dei soli CSV d'interesse.



- **Gateway & Biforcazione:**

- **Ramo Raw:** Salvataggio as-is per garanzia del dato originale.
- **Ramo Preprocessing:** Inoltro dei file d'interesse alla trasformazione.



NiFi Ingestion Pipeline: Preprocessing, Ottimizzazione e Handover

- **Imputazione e Sanitizzazione** - ScriptedTransformRecord:
 - Imputazione condizionale a zero dei valori nulli sulle cause di ritardo.
 - Correzione e normalizzazione dei valori negativi sporchi.
- **Data Quality & Filtraggio Selettivo** - QueryRecord:
 - Scarto dei record con chiavi primarie nulle o dati temporali mancanti.
 - Isolamento dei voli cancellati con orario di partenza presente.
 - Eliminazione dei record con anomalie logiche sulle metriche di ritardo.
- **Strategie di Conversione e Ottimizzazione:**
 - **Partition Pruning:** Il processore PartitionRecord converte in Parquet partizionando per chiavi temporali e carrier, permettendo a Spark l'esclusione di intere directory in lettura.
 - **Predicate Pushdown:** Il modulo MergeRecord compatta e converte in un singolo file Parquet per consentire a Spark il filtraggio diretto a livello di storage.




NiFi Ingestion Pipeline: Storage Finale e Handover ad Airflow

- **Storage Distribuito:** Scrittura dei file Parquet ottimizzati in HDFS o S3 a seconda della configurazione.
- **Notifica di Completamento:**
 - Chiamata HTTP PATCH via InvokeHTTP alle API di Airflow.
 - L'url di callback viene fornito nel payload di attivazione.

Payload JSON

```
{  
  "key": "${airflow.callback.variable_key}",  
  "value": "true"  
}
```



Computation Layer

Configurazione a Start-Time & Design Pattern Java

- **Parametrizzazione a Start-Time:**

- **Configurazione senza ricompilazione:** Gestione via YAML (`ApplicationConfig`) con override da **CLI**.
- **Selezione del Backend:** Scelta a runtime del paradigma di esecuzione (*RDD*, *DataFrame*, *SQL*), del partizionamento e delle strategie di calcolo (KLL vs T-Digest).
- **Storage Agnostic:** Disaccoppiamento totale dell'I/O su HDFS, S3, Local FS, PostgreSQL, CockroachDB, Redis e HBase.

- **Design Pattern Java:**

- **Template Method:** `BaseQuery.execute()` standardizza e unifica l'intero ciclo di vita del job Spark.
- **Factory & Repository:** `FlightRepositoryFactory` gestisce il polimorfismo, astruendo le connessioni ai database.
- **Strategy:** Switch dinamico degli algoritmi di calcolo (`PercentileSketch`) e delle modalità di esecuzione.
- **Singleton:** `PerformanceMetrics` come punto unico e centralizzato di raccolta delle metriche di esecuzione.

Query 1: Analisi Mensile Performance — RDD API

Obiettivo: Aggregare i voli 2025 (AA vs DL) su base mensile. Calcolare min, max, media di *DEP_DELAY* (solo voli non cancellati) e il *CANCELLATION RATE*.

Paradigm 1: RDD API

```
datasetVoli
  .mapToPair(v -> ([v.airline, v.month], v))
  .aggregateByKey(
    zeroValue: [sommaRitardi: 0, maxDelay: -∞, minDelay: +∞, nonCancellati: 0, totali: 0],
    combiner: (acc, v) -> {
      acc.totali += 1
      if !v.cancelled then
        acc.sommaRitardi += v.dep_delay
        acc.maxDelay = MAX(acc.maxDelay, v.dep_delay)
        acc.minDelay = MIN(acc.minDelay, v.dep_delay)
        acc.nonCancellati += 1
      return acc
    },
    reducer: (a1, a2) -> {
      a1.sommaRitardi += a2.sommaRitardi
      a1.maxDelay = MAX(a1.maxDelay, a2.maxDelay)
      a1.minDelay = MIN(a1.minDelay, a2.minDelay)
      a1.nonCancellati += a2.nonCancellati
      a1.totali += a2.totali
      return a1
    }
  )
  .map(tuple -> {
    media = ROUND(tuple.sommaRitardi / tuple.nonCancellati, 2)
    tasso_canc = ROUND((tuple.totali - tuple.nonCancellati) / tuple.totali * 100, 2)
    return Row(tuple.month, tuple.airline, media, tuple.minDelay, tuple.maxDelay, tasso_canc)
  })
```

Query 1: Analisi Mensile Performance — High-Level APIs

Obiettivo: Aggregare i voli 2025 (AA vs DL) su base mensile. Calcolare min, max, media di *DEP_DELAY* (solo voli non cancellati) e il *CANCELLATION RATE*.

Paradigm 2: DataFrame API (DSL)

```
datasetVoli
  .groupBy("MONTH", "OP_UNIQUE_CARRIER")
  .agg(
    round(avg(when(col("CANCELLED") == 0,
      col("DEP_DELAY"))), 2)
      .as("dep-delay-mean"),
    round(min(when(col("CANCELLED") == 0,
      col("DEP_DELAY"))), 2)
      .as("dep-delay-min"),
    round(max(when(col("CANCELLED") == 0,
      col("DEP_DELAY"))), 2)
      .as("dep-delay-max"),

    round(sum(col("CANCELLED")) /
      count("*") * 100, 2)
      .as("cancellation-rate")
  )
  .withColumnRenamed("MONTH", "month")
  .withColumnRenamed("OP_UNIQUE_CARRIER",
    "airline")
```

Paradigm 3: Spark SQL

```
SELECT
  MONTH                AS month,
  OP_UNIQUE_CARRIER AS airline,

  ROUND(AVG(CASE WHEN CANCELLED == 0
    THEN DEP_DELAY END), 2)
    AS ' dep-delay-mean',
  ROUND(MIN(CASE WHEN CANCELLED == 0
    THEN DEP_DELAY END), 2)
    AS ' dep-delay-min',
  ROUND(MAX(CASE WHEN CANCELLED == 0
    THEN DEP_DELAY END), 2)
    AS ' dep-delay-max',

  ROUND((SUM(CANCELLED) / COUNT(*))
    * 100, 2) AS ' cancellation-rate'

FROM flights
GROUP BY MONTH, OP_UNIQUE_CARRIER
```

Query 2: Top 10 Ritardi e Scomposizione Cause — RDD API

Obiettivo: Classifica prime 10 compagnie per *ARR_DELAY* medio decrescente (solo voli non cancellati/deviati con conteggio ≥ 500), mostrando l'incidenza media di ciascuna causa di ritardo.

Paradigm 1: RDD API

```
validFlights = flights.filter(f -> getSafe(f, CANCELLED) == 0 && getSafe(f, DIVERTED) == 0)

reducedRDD = validFlights
  .mapToPair(f -> (f.getString(OP_UNIQUE_CARRIER), f))
  .aggregateByKey(
    zeroValue: new double[7], // [0: Count, 1: Arr, 2: Carrier, 3: Weather, 4: NAS, 5: Security, 6: Late]
    combiner: (acc, f) -> {
      acc[0] += 1.0;      acc[1] += getSafe(f, ARR_DELAY);
      acc[2] += getSafe(f, CARRIER_DELAY); acc[3] += getSafe(f, WEATHER_DELAY);
      acc[4] += getSafe(f, NAS_DELAY);      acc[5] += getSafe(f, SECURITY_DELAY);
      acc[6] += getSafe(f, LATE_AIRCRAFT_DELAY);
      return acc;
    },
    reducer: (acc1, acc2) -> {
      for (int i=0; i<7; i++) acc1[i] += acc2[i];
      return acc1;
    }
  )

processedRDD = reducedRDD
  .filter(t -> t._2[0] >= 500.0)
  .map(t -> {
    double c = t._2[0];
    return RowFactory.create(t._1, (long)c, t._2[1]/c, t._2[2]/c, t._2[3]/c, t._2[4]/c, t._2[5]/c, t._2[6]/c);
  })

// Ordinamento globale ed estrazione Top 10 (Volume di record trascurabile post-filtraggio)
sortedRDD = processedRDD.sortBy(r -> r.getDouble(2), false, partitions)
top10RDD   = sortedRDD.zipWithIndex().filter(t -> t._2 < 10).map(t -> t._1).coalesce(1)
```

Query 2: Top 10 Ritardi e Scomposizione Cause — High-Level APIs

Obiettivo: Classifica prime 10 compagnie per *ARR_DELAY* medio decrescente (solo voli non cancellati/deviati con conteggio ≥ 500), mostrando l'incidenza media di ciascuna causa di ritardo.

Paradigm 2: DataFrame API (DSL)

```
flights
  .filter(col("CANCELLED").equalTo(0)
    .and(col("DIVERTED").equalTo(0)))
  .groupBy("OP_UNIQUE_CARRIER")
  .agg(
    count("*").as("num_flights"),
    round(avg(coalesce(col("ARR_DELAY"),
      lit(0))), 2).as("arrdelay_mean"),
    round(avg(coalesce(col("CARRIER_DELAY"),
      lit(0))), 2).as("carrier_mean"),
    round(avg(coalesce(col("WEATHER_DELAY"),
      lit(0))), 2).as("weather_mean"),
    round(avg(coalesce(col("NAS_DELAY"),
      lit(0))), 2).as("nas_mean"),
    round(avg(coalesce(col("SECURITY_DELAY"),
      lit(0))), 2).as("security_mean"),
    round(avg(coalesce(col("LATE_AIRCRAFT_DELAY"),
      lit(0))), 2).as("late_aircraft_mean")
  )
  .withColumnRenamed("OP_UNIQUE_CARRIER", "carrier")
  .filter(col("num_flights").geq(500))
  .orderBy(col("arrdelay_mean").desc())
  .limit(10)
```

Paradigm 3: Spark SQL

```
SELECT
  OP_UNIQUE_CARRIER AS carrier,
  COUNT(*)           AS num_flights,
  ROUND(AVG(COALESCE(ARR_DELAY, 0)), 2)
    AS arrdelay_mean,
  ROUND(AVG(COALESCE(CARRIER_DELAY, 0)), 2)
    AS carrier_delay_mean,
  ROUND(AVG(COALESCE(WEATHER_DELAY, 0)), 2)
    AS weather_delay_mean,
  ROUND(AVG(COALESCE(NAS_DELAY, 0)), 2)
    AS nas_delay_mean,
  ROUND(AVG(COALESCE(SECURITY_DELAY, 0)), 2)
    AS security_delay_mean,
  ROUND(AVG(COALESCE(LATE_AIRCRAFT_DELAY, 0)), 2)
    AS late_aircraft_delay_mean
FROM flights
WHERE CANCELLED = 0 AND DIVERTED = 0
GROUP BY OP_UNIQUE_CARRIER
HAVING num_flights >= 500
ORDER BY arrdelay_mean DESC
LIMIT 10
```

Query 3: Percentili Orari e Min/Max Globali — RDD API

Obiettivo: Calcolo dei percentili (25, 50, 75, 90) del *DEP_DELAY* per fascia oraria (24h) tramite algoritmi di sketch integrati (*KLL/t-digest*) e calcolo parallelo di min/max globali per vettore (AA, DL, UA, WN).

Paradigm 1: RDD API (Dual-Pipeline Architecture)

```
// Subset condiviso e mantenuto in memoria per evitare scansioni multiple
validFlights = flights.filter(f -> f.getDouble(CANCELLED) == 0.0 && !f.isNullAt(DEP_DELAY)).cache()

% Pipeline 1: Calcolo Percentili Orari tramite Sketch distribuiti
PercentileSketch sketch = PercentileSketch.from(config.getPercentileAlgorithm())
hourlyRows = validFlights
    .filter(f -> !f.isNullAt(CRS_DEP_TIME))
    .mapToPair(f -> {
        int hour = (f.getInt(CRS_DEP_TIME) / 100) % 24;
        return new Tuple2<>(new Tuple2<>(f.getString(CARRIER), hour), f.getDouble(DEP_DELAY));
    })
    .combineByKey(sketch::init, sketch::update, sketch::merge)
    .map(t -> {
        double[] q = sketch.getQuantiles(t._2, 0.25, 0.50, 0.75, 0.90);
        return RowFactory.create(t._1._1, t._1._2, round2(q[0]), round2(q[1]), round2(q[2]), round2(q[3]));
    })

% Pipeline 2: Aggregazione Globale Min/Max per Compagnia (Evitando overhead di array transienti)
globalRows = validFlights
    .mapToPair(f -> new Tuple2<>(f.getString(CARRIER), f))
    .aggregateByKey(
        zeroValue: new double[] {Double.MAX_VALUE, -Double.MAX_VALUE},
        combiner: (acc, f) -> {
            double d = f.getDouble(DEP_DELAY);
            acc[0] = Math.min(acc[0], d); acc[1] = Math.max(acc[1], d);
            return acc;
        },
        reducer: (a1, a2) -> {
            a1[0] = Math.min(a1[0], a2[0]); a1[1] = Math.max(a1[1], a2[1]);
            return a1;
        }
    )
```

Query 3: Percentili Orari e Min/Max Globali — High-Level APIs

Obiettivo: Calcolo dei percentili (25, 50, 75, 90) del *DEP_DELAY* per fascia oraria (24h) tramite algoritmi di sketch integrati (*KLL/t-digest*) e calcolo parallelo di min/max globali per vettore (AA, DL, UA, WN).

Paradigm 2: DataFrame API (DSL)

```
flights.cache()

// Pipeline 1: Percentili orari approssimati
hourlyStats = flights
  .filter(col("CANCELLED").equalTo(0))
  .withColumn("hour",
    col("CRS_DEP_TIME").divide(100).cast("int"))
  .groupBy("OP_UNIQUE_CARRIER", "hour")
  .agg(
    round(expr("percentile_approx(DEP_DELAY, 0.25)"), 2).as("p25"),
    round(expr("percentile_approx(DEP_DELAY, 0.50)"), 2).as("p50"),
    round(expr("percentile_approx(DEP_DELAY, 0.75)"), 2).as("p75"),
    round(expr("percentile_approx(DEP_DELAY, 0.90)"), 2).as("p90")
  )
  .withColumnRenamed("OP_UNIQUE_CARRIER", "airline")

// Pipeline 2: Min/Max assoluti
globalMinMax = flights
  .groupBy("OP_UNIQUE_CARRIER")
  .agg(
    min("DEP_DELAY").as("min_delay"),
    max("DEP_DELAY").as("max_delay")
  )
  .withColumnRenamed("OP_UNIQUE_CARRIER", "airline")
```

Paradigm 3: Spark SQL

```
flights.cache()

// Pipeline 1: Stima quantili con funzioni built-in
String hourlySql =
  "SELECT OP_UNIQUE_CARRIER as airline, " +
  "CAST(CRS_DEP_TIME / 100 AS INT) AS hour, " +
  "ROUND(percentile_approx(DEP_DELAY, 0.25), 2) AS p25, " +
  "ROUND(percentile_approx(DEP_DELAY, 0.50), 2) AS p50, " +
  "ROUND(percentile_approx(DEP_DELAY, 0.75), 2) AS p75, " +
  "ROUND(percentile_approx(DEP_DELAY, 0.90), 2) AS p90 " +
  "FROM flights " +
  "WHERE CANCELLED = 0 " +
  "GROUP BY OP_UNIQUE_CARRIER, hour";

hourlyStats = spark.sql(hourlySql);

// Pipeline 2: Estremi globali
String globalSql =
  "SELECT OP_UNIQUE_CARRIER as airline, " +
  "MIN(DEP_DELAY) AS min_delay, " +
  "MAX(DEP_DELAY) AS max_delay " +
  "FROM flights " +
  "GROUP BY OP_UNIQUE_CARRIER";

globalMinMax = spark.sql(globalSql);
```

Algoritmi Percentili a Confronto: T-Digest vs KLL Sketch

T-Digest (Ted Dunning's Library)

- **Accuratezza:** $\sim 1\%$ di errore relativo nelle **code (tails)** del dataset.
- **Parametro chiave:** COMPRESSION = 100.0.
- **Meccanismo di Serializzazione:**

```
// Inizializzazione e manipolazione buffer
MergingDigest digest = new MergingDigest(100.0);

// Update / Merge a runtime via ByteBuffer
MergingDigest.fromBytes(ByteBuffer.wrap(state));

// Compattazione in byte array
ByteBuffer buf = ByteBuffer.allocate(
    digest.smallByteSize()
);
digest.asSmallBytes(buf);
return buf.array();
```

→ Ottimo per l'analisi accurata degli estremi (es. ritardi record).

KLL Sketch (Apache DataSketches)

- **Accuratezza:** Errore di rango normalizzato bi-laterale di $\sim 1.65\%$ (simile a `percentile_approx`).
- **Parametro chiave:** Default $k=200$ (bilanciamento ottimale).
- **Meccanismo di Serializzazione:**

```
// Allocazione nativa in Heap
KllDoublesSketch.newHeapInstance();

// Ricostruzione stato tramite org.apache.datasketches.memory.Memory
KllDoublesSketch.heapify(Memory.wrap(state));

// Export diretto nativo ultra-veloce
return sketch.toByteArray();

// Estrazione quantili con criterio inclusivo
sketch.getQuantile(q, QuantileSearchCriteria.INCLUSIVE);
```

→ Più veloce nell'I/O grazie all'integrazione nativa con lo strato Memory.

Query 4: Airline Clustering — ML Pipeline

Obiettivo: Individuare gruppi di vettori aerei con comportamenti e cause di ritardo simili sui top 15 carrier stabili, standardizzando lo spazio multivariato ed applicando l'algoritmo K-Means.

- **1. Feature Ingestion & Vettorizzazione:** Estrazione di 11 metriche aggregate (medie, deviazioni standard dei ritardi, tassi di cancellazione e deviazioni). Assemblaggio dello spazio multivariato tramite `VectorAssembler`.
- **2. Z-Score Normalization:** Uso di `StandardScaler` per azzerare la media (`withMean`) e scalare sulla varianza unitaria (`withStd`) per rendere confrontabili metriche a scale diverse.

Selezione del K Ottimale tramite Silhouette Analysis (MLlib DataFrame API)

```
// Analisi iterativa dello score di Silhouette per minimizzare l'arbitrarietà di K
ClusteringEvaluator evaluator = new ClusteringEvaluator()
    .setFeaturesCol("features").setPredictionCol("prediction").setMetricName("silhouette");

int bestK = 2; double bestScore = -1.0;

for (int k = 2; k <= 5; k++) {
    KMeans kmeans = new KMeans().setK(k).setSeed(42L).setInitMode("k-means||");
    KMeansModel model = kmeans.fit(scaledData);

    double score = evaluator.evaluate(model.transform(scaledData));
    if (score > bestScore) {
        bestScore = score; bestK = k;
    }
}

// Esecuzione finale del fit di K-Means sul "bestK" identificato
KMeansModel modelFinal = new KMeans().setK(bestK).setSeed(42L).fit(scaledData);
```

Query 4: Airline Clustering — Proiezione e Vincoli Architettureali

Obiettivo: Individuare gruppi di vettori aerei con comportamenti e cause di ritardo simili sui top 15 carrier stabili, standardizzando lo spazio multivariato ed applicando l'algoritmo K-Means.

Proiezione PCA per la Visualizzazione

- Il clustering avviene nello spazio nativo a 11 dimensioni.
- **Principal Component Analysis:** Applicata *dopo* il clustering esclusivamente per mappare i punti e i centroidi su un piano cartesiano 2D (CHART_DIMENSION = 2).

```
PCA pca = new PCA()
    .setInputCol("features")
    .setOutputCol("pca_features")
    .setK(2);
PCAModel pcaModel = pca.fit(finalPredictions);

// Espansione del vettore nei componenti x e y
Dataset<Row> finalOutput = appendPcaColumns(
    pcaModel.transform(finalPredictions)
);
```

Vincoli e Limitazioni delle API

- **Esclusività del DataFrame:** L'intero algoritmo si appoggia sulle interfacce di `org.apache.spark.ml`, strutturate per operare su contesti fortemente tipizzati di tipo `Dataset<Row>`.

```
@Override
protected List<Row> runQuerySQL(...) {
    throw new
        UnsupportedOperationException(
            "Clustering only via DataFrame");
}

@Override
protected List<Tuple2> runQueryRDD(...) {
    throw new
        UnsupportedOperationException(
            "Clustering only via DataFrame");
}
```


- Lo strato SQL non possiede costrutti dichiarativi per pipeline iterative

- **Obiettivo:** Misurazione rigorosa dei tempi di esecuzione per il benchmarking.
- **JobTimerListener:**
 - Estensione di `SparkListener` per intercettare gli eventi del DAG Scheduler.
 - Monitoraggio di `onJobStart` e `onJobEnd`.
- **Precisione:** Eliminazione degli overhead di sistema, I/O Driver e task "lazy", garantendo metriche focalizzate puramente sul tempo di calcolo distribuito.

Airflow Orchestration

Orchestrazione End-to-End: `flight_analysis`

- **Obiettivo:** Orchestrare l'intera pipeline, dall'ingestion in NiFi all'elaborazione Spark.
- **Funzionalità:** Utilizzo della **TaskFlow API** (Airflow 3.0) per gestire il branching condizionale (*Ingest Only*, *Execution Only*, *Both*).
- **Sincronizzazione:** Uso di `Task.Sensor` per attendere il completamento asincrono di NiFi.



- **Obiettivo:** Raccolta automatizzata delle metriche prestazionali in ambiente EC2.
- **Logica:** Loop sequenziale per eseguire tutte le 12 combinazioni (4 Query $\times$ 3 Backend).
- **Integrazione:** Sottomissione dei job tramite LivyOperator verso il Master Node.

Integrazione Livy (EC2)

```
spark_task = LivyOperator(  
    task_id=task_id,  
    livy_conn_id="livy_default",  
    file=JAR_PATH,  
    class_name=JAR_CLASS,  
    args=[  
        "--query", query,  
        "--backend", backend,  
        "--config", "{{ params.config_file }}",  
        "--input-type", "{{ params.input_type }}",  
        "--output-type", "{{ params.output_type }}",  
        "--metrics-type", "{{ params.metrics_type }}"  
    ],  
    name=f"benchmark-{query}-{backend}",  
    polling_interval=5  
)
```

- **Obiettivo:** Benchmarking su **AWS EMR** per testare la scalabilità managed.
- **Logica:** Esecuzione delle 12 combinazioni in modalità sequenziale.
- **Integrazione Cloud:** Uso di `EmrAddStepsOperator` e `EmrStepSensor`.

Integrazione EMR Step (AWS)


```
spark_step = {
    "Name": step_name,
    "ActionOnFailure": "CONTINUE",
    "HadoopJarStep": {
        "Jar": "command-runner.jar",
        "Args": [
            "spark-submit", "--deploy-mode", "client",
            "--class", JAR_CLASS, JAR_PATH,
            "--query", query, ...
        ],
    },
}

add_step = EmrAddStepsOperator(
    task_id=tid,
    job_flow_id="{ params.job_flow_id }",
    aws_conn_id="aws_default",
    steps=[spark_step],
)


watch_step = EmrStepSensor(
    task_id=task_id,
    job_flow_id="{ params.job_flow_id }",
    step_id=f"{{{ ti.xcom_pull(task_ids='{tid}') [0] }}}",
    aws_conn_id="aws_default",
    poke_interval=30,
)
```

Valutazione Sperimentale

EC2 Deployment



EMR Deployment



- **Rigore Statistico:** Ogni combinazione (Query $\times$ Backend) è stata eseguita **5 volte** per garantire la stabilità delle misurazioni.
- **Telemetria:** Utilizzo del JobTimerListener (SparkListener) per isolare il *tempo netto di calcolo* dall'overhead di sistema.
- **Hardware e Infrastruttura:**
 - **EC2 (Self-Hosted):** Master + Worker su istanze t3.small. Storage basato su HDFS.
 - **EMR (Cloud-Native):** 1 Master + 3 Core su istanze m6g.xlarge (ARM64). Architettura *Shared-Nothing* su Amazon S3 via s3a://.

Confronto API: RDD vs DataFrame vs SQL

- **DataFrame/SQL:** Massima stabilità e minori tempi di esecuzione nelle query di aggregazione (es. Q1) grazie all'ottimizzatore *Catalyst* e alla gestione binaria off-heap di *Tungsten*.
- **RDD:** Più performante in task atomici e logiche distribuite custom (Q2 e Q3), nonostante il maggior overhead di serializzazione JVM.



Ottimizzazione I/O: Pruning vs Pushdown

- **Partition Pruning:** Strategia ottimale. Esclude i dati a livello di file system, garantendo un I/O bilanciato e l'assenza di *Workload Skew* sui nodi.
- **Predicate Pushdown:** Richiede la scansione dei metadati Parquet. Genera un volume di lettura superiore e tende a sovraccaricare singoli nodi (colli di bottiglia in fase di scansione).



Overhead Infrastrutturale: EC2 vs EMR

- **Standalone (EC2):** Overhead di *Wall Clock Time* significativo dovuto ai tempi di negoziazione delle risorse, bootstrap del cluster e latenze di rete HDFS.
- **Managed (EMR):** L'integrazione nativa con S3 e la gestione elastica delle istanze contraggono sensibilmente i "tempi morti", massimizzando l'efficienza temporale del job.




Risultati Analitici

Query 3: Scelta dell'Euristica e Approssimazione

- **Problema:** Calcolo dei percentili esatti su RDD (groupByKey) causa *Out Of Memory* e colli di bottiglia distribuiti.
- **Soluzione:** Implementazione di algoritmi di **Quantile Sketching** (T-Digest e KLL).
- **Analisi Comparativa:**
 - **KLL Sketch:** Elevata precisione teorica, ma footprint di memoria superiore.
 - **T-Digest:** Ottimizzato per le "code" della distribuzione e più performante.
- **Validazione:** Risultati pressoché identici sul dataset reale; la convergenza dei dati giustifica l'uso di algoritmi probabilistici.
- **Scelta Finale:** **T-Digest** per il miglior rapporto performance/accuratezza nel dominio aeronautico.


Q3 — Departure Delay Probabilistic Distribution (AA) ⓘ




Risultati Analitici: Airline Clustering (Q4)

- **Model Selection:** Identificazione di $K = 3$ come numero ottimale di cluster tramite *Silhouette Score*.
- **Profilazione dei Cluster:**
 - **Cluster 0 (Inefficienza):** AA, OH, F9. Elevata propagazione dei ritardi e instabilità operativa.
 - **Cluster 1 (Sensibilità Esterna):** G4. Forti ritardi meteorologici ma bassissimo tasso di cancellazione.
 - **Cluster 2 (Virtuosi):** DL, UA, WN. Alta capacità di recupero in volo (*Delay Makeup*) e stabilità.
- **Visualizzazione:** Proiezione PCA bidimensionale (perdita di varianza fisiologica rispetto al modello ad alta dimensionalità).


Q4 — Latent Performance Clusters (PCA Projection) ⓘ



Q4 — Multi-dimensional Centroid Profiles ⓘ



Q4 — Population Distribution by Cluster ⓘ




Risultati Analitici: Query 1 e Query 2

- **Query 1 (Trend):** Divergenza tra **Delta** (miglioramento costante, ritardi < 10 min) e **American Airlines** (degrado progressivo e maggiori cancellazioni).
- **Query 2 (Ranking):**
 - **PSA Airlines (OH):** Peggior vettore per ritardo all'arrivo (17.16 min), causato da forte propagazione (*late aircraft delay*).
 - **United (UA):** Più efficiente tra i grandi vettori, ma penalizzato da fattori esterni (*NAS delay*).
- **Insight:** SAE decodifica con precisione le inefficienze strutturali vs eventi esterni.

Q1 — Average Departure Delay Trend (AA vs DL) ⓘ



Q2 — Top 10 Delayed Airlines (Arrival) ⓘ



Conclusioni

- **Modularità:** L'architettura disaccoppiata (NiFi-Airflow-Spark) garantisce scalabilità ed estensibilità.
- **Efficienza:** Il formato Parquet e il Partition Pruning sono fondamentali per abbattere l'I/O overhead.
- **Insight:** La piattaforma trasforma dataset massivi in profili operativi chiari per il business.
- **Sviluppi Futuri:** Transizione verso un'architettura Lambda per il processing in streaming real-time.



TOR VERGATA
UNIVERSITÀ DEGLI STUDI DI ROMA